

Heart Disease Detection Project Report

گزارش پروژه تشخیص بیماری قلبی

تهیه کننده: فاطمه اقوامی

مقدمه

این پروژه با هدف تشخیص بیماری قلبی با استفاده از الگوریتم‌های یادگیری ماشین انجام شده است. با توجه به اهمیت تشخیص زودهنگام بیماری‌های قلبی، تمرکز اصلی ارزیابی مدل‌ها بر معیار Recall (Sensitivity) قرار داده شده است. این معیار اهمیت بالایی دارد زیرا شناسایی صحیح افراد بیمار (کاهش False Negatives) در زمینه پزشکی حیاتی است.

مجموعه داده

داده‌های مورد استفاده از مخزن UCI Machine Learning Repository (Cleveland Heart Disease Dataset) دریافت شده‌اند. این مجموعه شامل ۱۳ ویژگی بالینی (مانند سن، جنسیت، فشار خون، کلسترول و...) و یک متغیر هدف است که وجود یا عدم وجود بیماری قلبی را نشان می‌دهد.

پاکسازی داده‌ها: مقادیر گمشده (Missing Values) از داده‌ها حذف شده‌اند. پس از حذف، مجموعه داده نهایی برای آموزش مدل‌ها آماده‌سازی گردید. متغیر هدف (Target Variable) که نشان‌دهنده وجود بیماری است، به صورت دودویی (۰: سالم، ۱: بیمار) تبدیل شده است.

پیش‌پردازش داده‌ها

مراحل پیش‌پردازش برای آماده‌سازی داده‌ها جهت آموزش الگوریتم‌های یادگیری ماشین شامل مراحل زیر بود:

- بارگذاری داده‌ها: بارگذاری مجموعه داده از منبع اصلی و بررسی ساختار کلی داده‌ها.
- حذف داده‌های نال: حذف سطرهایی که دارای مقادیر گمشده بودند تا از سوگیری در مدل‌سازی جلوگیری شود.

3. نرمال سازی ویژگی ها: از آنجایی که ویژگی ها دارای مقیاس های متفاوتی بودند، از StandardScaler برای نرمال سازی استفاده شد. این امر باعث می شود ویژگی ها میانگین صفر و واریانس یک داشته باشند:

$$X_{\text{normalized}} = \frac{X - \mu}{\sigma}$$

1. تقسیم داده ها: داده ها به دو مجموعه آموزش (Training Set) و آزمون (Test Set) با نسبت ۸۰٪ آموزش و ۲۰٪ آزمون تقسیم شدند.
- همچنین ماتریس همبستگی ویژگی ها جهت تحلیل اولیه و شناسایی همبستگی های قوی یا چندگانگی خطی (Multicollinearity) ترسیم و ذخیره شده است.

مدل های یادگیری ماشین

سه مدل طبقه بندی اصلی در این پروژه به کار گرفته شده اند تا عملکرد آن ها بر روی داده های تست مقایسه شود. این مدل ها بر روی داده های یکسان آموزش داده شده اند:

1. Logistic Regression: به عنوان یک مدل خطی پایه که قابلیت تفسیر بالایی دارد.
2. K-Nearest Neighbors (KNN): با پارامتر $k=5$ که یک مدل مبتنی بر مجاورت است.
3. Random Forest: با تنظیم ۱۰۰ درخت ($n_estimators=100$) که یک روش یادگیری گروهی (Ensemble) قدرتمند است.

معیارهای ارزیابی

برای ارزیابی دقیق عملکرد مدل ها، به ویژه با توجه به اهمیت تشخیص بیماری، معیارهای زیر مورد استفاده قرار گرفتند:

- Accuracy (دقت کلی): نسبت پیش بینی های صحیح به کل پیش بینی ها.
- Recall (Sensitivity): توانایی مدل در شناسایی صحیح افراد بیمار (مثبت های واقعی):

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

- F1-Score: میانگین هارمونیک دقت (Precision) و فراخوانی (Recall).
- Cross-Validation Recall (5-Fold): ارزیابی میانگین Recall مدل با استفاده از اعتبارسنجی متقابل ۵-بخشی برای اطمینان از تعمیم پذیری مدل.

علاوه بر معیارهای عددی، تحلیل بصری زیر نیز انجام شد:

- Confusion Matrix: برای نمایش تعداد True Positives, False Positives, True Negatives و False Negatives.
 - ROC Curve: برای ارزیابی عملکرد مدل در سطوح مختلف آستانه طبقه‌بندی، با محاسبه Area Under the Curve (AUC).
-

جمع‌بندی

نتایج آزمایش‌ها بر روی مجموعه داده آزمون به شرح زیر بود:

مدل Random Forest با کسب بالاترین مقدار Recall نشان داد که در شناسایی افراد بیمار (کاهش نرخ مثبت کاذب منفی) عملکرد برتری نسبت به سایر مدل‌ها دارد. این مدل به دلیل ماهیت قوی خود در مدیریت داده‌های پیچیده، بهترین عملکرد کلی را ارائه داد.

در مقابل، مدل Logistic Regression با وجود اینکه ممکن است از نظر Recall کمی پایین‌تر باشد، به دلیل تفسیرپذیری بالا (قابلیت استخراج وزن و اهمیت ویژگی‌ها)، همچنان گزینه‌ای بسیار مناسب برای کاربردهای پزشکی محسوب می‌شود که در آن نیاز به فهم دلیل تصمیم‌گیری مدل وجود دارد.

تذکر مهم: این پروژه صرفاً جنبه آموزشی و اثبات مفهوم (Proof of Concept) دارد و نتایج حاصل از آن نباید به عنوان جایگزین تشخیص پزشکی واقعی توسط متخصصین مورد استفاده قرار گیرد.